
Prédiction de la Potabilité de l'Eau

Classification binaire · Application terrain · Santé publique

Projet H2 — Machine Learning Appliqué

Équipe :

Aguiratou NITIEMA
Yassine OUEDRAOGO
Solange ILINGA

GitHub :

<https://github.com/projet-potabilite-eau.git>

Techniques :

Classification binaire (RF, XGBoost, LR, SVM)

Dataset :

Water Potability Dataset — Kaggle

Date :

05 Juin 2026

Table des matières

1	Introduction	3
1.1	Contexte et problématique	3
1.2	Objectif du projet	3
1.3	Structure du rapport	3
2	Données et Exploration	4
2.1	Description du dataset	4
2.2	Variables du dataset	4
2.3	Analyse exploratoire (EDA)	4
2.3.1	Déséquilibre des classes	4
2.3.2	Valeurs manquantes	5
2.3.3	Stratégie d'imputation	5
2.3.4	Distributions et corrélations	5
3	Modélisation	7
3.1	Méthodologie	7
3.1.1	Préparation des données	7
3.1.2	Modèles entraînés	7
3.2	Résultats et comparaison	7
3.2.1	Métriques de performance	7
3.2.2	Analyse des scores	8
3.2.3	Courbes ROC	8
3.3	Diagnostic et correction de l'overfitting	8
3.3.1	Problème identifié	8
3.3.2	Corrections appliquées — Random Forest	8
3.3.3	Corrections appliquées — XGBoost	9
3.3.4	Impact des corrections	9
4	Optimisation et Interprétabilité	11
4.1	Optimisation du seuil de décision	11
4.1.1	Justification d'un seuil asymétrique	11
4.1.2	Méthode d'optimisation	11
4.2	Analyse SHAP	11
4.2.1	Principe	11
4.2.2	Résultats SHAP	12
4.3	Validation croisée	12

5	Application Streamlit	14
5.1	Description de l'application	14
5.2	Architecture de l'application	14
5.3	Lancer l'application	14
5.4	Accès à l'application	15
5.5	Code source	15
6	Conclusion et Perspectives	16
6.1	Bilan du projet	16
6.2	Limites	16
6.3	Perspectives	16
	Références	17

Chapitre 1

Introduction

1.1 Contexte et problématique

En Afrique de l'Ouest, des millions de personnes n'ont pas accès à de l'eau potable sûre, faute de laboratoires d'analyse en zones rurales. Selon l'Organisation Mondiale de la Santé (OMS), 6% de décès par an dans le monde sont d'origine hydrique .

Problématique centrale : Comment déterminer rapidement et de manière automatisée si une source d'eau est potable ou non, à partir de mesures physico-chimiques simples effectuées sur le terrain ?

1.2 Objectif du projet

L'objectif principal de ce projet est de :

1. **Construire un classificateur binaire** à partir de paramètres physico-chimiques de l'eau (pH, turbidité, conductivité, dureté, nitrates, sulfates, etc.) déterminant si une source d'eau est potable (1) ou non potable (0).
2. **Optimiser le seuil de décision** de façon asymétrique, en pénalisant davantage les faux négatifs dangereux (eau non potable classée potable).
3. **Interpréter les décisions** du modèle via l'analyse SHAP, pour identifier les paramètres les plus critiques.
4. **Déployer une application Streamlit** utilisable sur le terrain par du personnel non technique.

1.3 Structure du rapport

Ce rapport est organisé comme suit : le Chapitre 2 décrit le dataset et l'exploration des données. Le Chapitre 3 présente les modèles de machine learning utilisés, leurs performances ainsi que le diagnostic et la correction de l'overfitting. Le Chapitre 4 détaille l'optimisation du seuil de décision et l'interprétabilité SHAP. Le Chapitre 5 décrit l'application Streamlit déployée. Enfin, le Chapitre 6 conclut et propose des perspectives.

Chapitre 2

Données et Exploration

2.1 Description du dataset

TABLE 2.1 – Informations générales sur le dataset

Nom	Water Potability Dataset
Source	Kaggle
URL	kaggle.com/datasets/adityakadiwal/water-potability
Taille	3 276 échantillons $\times$ 10 colonnes
Cible	Potability : 1 = potable, 0 = non potable
Format	CSV, téléchargement immédiat

2.2 Variables du dataset

Le dataset contient 9 variables prédictives et 1 variable cible :

TABLE 2.2 – Description des variables physico-chimiques

Variable	Unité	Description	Norme OMS
ph	–	Acidité/alcalinité de l'eau	6.5 – 8.5
Hardness	mg/L	Dureté (teneur en calcium/magnésium)	< 300
Solids	ppm	Total des solides dissous (TDS)	< 500
Chloramines	ppm	Désinfectant chloré	< 4.0
Sulfate	mg/L	Concentration en sulfates	< 250
Conductivity	$\mu\text{S}/\text{cm}$	Conductivité électrique	< 400
Organic_carbon	ppm	Carbone organique total	< 2.0
Trihalomethanes	$\mu\text{g}/\text{L}$	Sous-produits de chloration	< 80
Turbidity	NTU	Clarté de l'eau (trouble)	< 4.0
Potability	–	Cible : 0 = non potable, 1 = potable	–

2.3 Analyse exploratoire (EDA)

2.3.1 Déséquilibre des classes

La variable cible présente un déséquilibre modéré :

TABLE 2.3 – Distribution de la variable cible

Classe	Effectif	Proportion
0 — Non potable	1 998	61.0%
1 — Potable	1 278	39.0%
Total	3 276	100%

2.3.2 Valeurs manquantes

TABLE 2.4 – Valeurs manquantes par variable



Variable	Valeurs manquantes	Pourcentage
ph	491	15.0%
Sulfate	781	23.8%
Trihalomethanes	162	4.9%
Autres variables	0	0%

2.3.3 Stratégie d'imputation

Nous avons utilisé l'**imputation KNN** (k=5 voisins) plutôt qu'une simple imputation par médiane, car elle préserve mieux les corrélations entre variables.

2.3.4 Distributions et corrélations

L'analyse des distributions par classe révèle que les variables **pH**, **Sulfate** et **Chloramines** présentent les différences les plus marquées entre eau potable et non potable. La matrice de corrélation montre une faible corrélation entre les variables prédictives, ce qui est favorable pour les modèles linéaires. Ce résultat est confirmé ensuite par l'analyse SHAP.



Chapitre 3

Modélisation

3.1 Méthodologie

3.1.1 Préparation des données

Les données nettoyées sont divisées en ensembles d'entraînement (80%) et de test (20%), avec stratification sur la variable cible.

Une normalisation `StandardScaler` est appliquée pour la Régression Logistique et le SVM. Les modèles à base d'arbres (RF, XGBoost) reçoivent les données non normalisées.

3.1.2 Modèles entraînés

Quatre algorithmes de classification binaire ont été entraînés et comparés :

TABLE 3.1 – Modèles de classification entraînés

Modèle	Configuration principale
Logistic Regression	<code>max_iter=1000, class_weight="balanced"</code>
Random Forest	<code>n_estimators=200, max_depth=12, min_samples_leaf=5, min_samples_split=10</code>
XGBoost	<code>n_estimators=200, max_depth=4, reg_alpha=0.1, reg_lambda=1.5, scale_pos_weight</code> calibré
SVM	<code>kernel=rbf, probability=True, class_weight="balanced"</code>

3.2 Résultats et comparaison

3.2.1 Métriques de performance

TABLE 3.2 – Comparaison des performances des modèles sur l'ensemble de test

Modèle	Train AUC	AUC-ROC	Gap	F1	Rang
Logistic Regression	0.515	0.547	-0.032	0.56	4 ^e
SVM	0.789	0.639	0.150	0.58	3 ^e
Random Forest	0.906	0.674	0.232	0.59	2 ^e
XGBoost	0.881	≈ 0.70	0.181	≈ 0.60	1^{er}

Meilleur modèle : XGBoost avec AUC-ROC ≈ 0.70 et F1-Score ≈ 0.60 , sélectionné automatiquement et sauvegardé dans `best_model.pkl`.

3.2.2 Analyse des scores

Les performances modérées observées (AUC-ROC ≈ 0.70) sont cohérentes avec les résultats publiés sur Kaggle pour ce dataset. Trois facteurs expliquent cette limitation :

1. **Fort taux de valeurs manquantes** (jusqu'à 24% sur Sulfate) introduisant du bruit même après imputation.
2. **Déséquilibre de classes** (61% / 39%) rendant la discrimination plus difficile.
3. **Chevauchement des distributions** : les 9 paramètres ne séparent pas clairement les deux classes dans l'espace des features.

3.2.3 Courbes ROC

Les courbes ROC confirment la supériorité de XGBoost sur les autres modèles sur l'ensemble de test, avec une aire sous la courbe (AUC) significativement supérieure à la ligne de base aléatoire (AUC = 0.50).

3.3 Diagnostic et correction de l'overfitting

3.3.1 Problème identifié

Overfitting détecté : Sans régularisation, Random Forest et XGBoost atteignaient un Train AUC de **1.000**, chutant à 0.66 et 0.63 en test (gap > 0.30). Les modèles mémorisaient les données d'entraînement au lieu d'apprendre des règles généralisables.

3.3.2 Corrections appliquées — Random Forest

Listing 3.1 – Random Forest régularisé

```
1 RandomForestClassifier(  
2     n_estimators=200,  
3     max_depth=12,           # limite la profondeur des arbres  
4     min_samples_leaf=5,     # feuille : au moins 5 exemples  
5     min_samples_split=10,   # noeud : au moins 10 exemples  
                               pour se diviser  
6     max_features="sqrt",    # sous-ensemble aleatoire de  
                               features
```

```

7     class_weight="balanced",
8     random_state=42
9 )

```

3.3.3 Corrections appliquées — XGBoost

Listing 3.2 – XGBoost régularisé

```

1 XGBClassifier(
2     n_estimators=200,
3     max_depth=4,           # arbres peu profonds
4     learning_rate=0.05,    # apprentissage lent et stable
5     min_child_weight=5,    # poids minimum d'un noeud fils
6     subsample=0.8,        # 80% des donnees par arbre
7     colsample_bytree=0.8,  # 80% des features par arbre
8     reg_alpha=0.1,         # regularisation L1
9     reg_lambda=1.5,        # regularisation L2
10    scale_pos_weight=...,
11    random_state=42
12 )



```

3.3.4 Impact des corrections

TABLE 3.3 – Impact de la régularisation sur l'overfitting et le F1-Score

Modèle	Gap avant	Gap après	F1 avant	F1 après
Random Forest	0.342	0.232	0.40	0.59
XGBoost	0.374	0.181	0.48	0.60

La régularisation réduit le gap train/test et améliore le F1-Score de **+50%** sur Random Forest.



Chapitre 4

Optimisation et Interprétabilité

4.1 Optimisation du seuil de décision

4.1.1 Justification d'un seuil asymétrique

Dans un contexte de santé publique, les deux types d'erreurs n'ont pas le même coût :

TABLE 4.1 – Asymétrie des coûts d'erreur

Erreur	Description	Conséquence
Faux Positif (FP)	Eau potable classée non potable	Inconvénient, gaspillage
Faux Négatif (FN)	Eau non potable classée potable	DANGER DE VIE

Un faux négatif dans ce contexte signifie qu'une communauté consomme de l'eau contaminée en pensant qu'elle est sûre. Ce type d'erreur est inacceptable, le seuil doit être calibré pour le minimiser.

4.1.2 Méthode d'optimisation

Le seuil τ optimal est déterminé en maximisant le F1-Score sous contrainte que le rappel de la classe "Non potable" reste supérieur à 70%.

$$\tau^* = \arg \max_{\tau \in [0.1, 0.9]} F1(\tau) \quad \text{tel que} \quad \text{Recall}_0(\tau) \geq 0.70 \quad (4.1)$$

Le seuil optimal obtenu est généralement autour de $\tau^* \approx 0.40$, inférieur au seuil par défaut de 0.50, ce qui augmente la sensibilité aux cas non potables.

4.2 Analyse SHAP

4.2.1 Principe

SHAP (SHapley Additive exPlanations) est une méthode d'interprétabilité basée sur la théorie des jeux de Shapley. Pour chaque prédiction, elle calcule la contribution de chaque feature à l'écart par rapport à la prédiction moyenne :

$$f(x) = \phi_0 + \sum_{i=1}^9 \phi_i(x) \quad (4.2)$$

où ϕ_0 est la valeur de base (prédiction moyenne) et $\phi_i(x)$ est la valeur SHAP de la feature i pour l'instance x .

4.2.2 Résultats SHAP

L'analyse SHAP sur XGBoost révèle le classement d'importance des features suivant :

TABLE 4.2 – Importance des features selon SHAP (valeurs moyennes absolues)

Rang	Feature	Importance relative
1	Sulfate	Très élevée
2	pH	Élevée
3	Chloramines	Élevée
4	Conductivity	Modérée
5	Organic_carbon	Modérée
6	Trihalomethanes	Faible
7	Turbidity	Faible
8	Hardness	Faible
9	Solids	Très faible

Insight clé : Le Sulfate, le pH et les Chloramines sont les trois paramètres les plus déterminants pour prédire la potabilité. Sur le terrain, prioriser la mesure précise de ces trois variables optimise la fiabilité du diagnostic.


4.3 Validation croisée

Une validation croisée stratifiée à 5 folds confirme la robustesse du modèle :

TABLE 4.3 – Résultats de la validation croisée 5-fold stratifiée

Métrique	Moyenne	Écart-type
F1-Score	≈ 0.59	± 0.02
AUC-ROC	≈ 0.70	± 0.02
Precision	≈ 0.63	± 0.03
Recall	≈ 0.56	± 0.03

Le faible écart-type confirme que le modèle généralise bien et n'est pas en sur-apprentissage.



Chapitre 5

Application Streamlit

5.1 Description de l'application

Une application web interactive a été développée avec **Streamlit** pour permettre une utilisation terrain par du personnel non technique. L'interface permet de saisir les 9 paramètres physico-chimiques mesurés sur un échantillon d'eau et d'obtenir instantanément :

- Un **verdict clair** : **EAU POTABLE** ou **EAU NON POTABLE**
- La **probabilité de potabilité** (score entre 0 et 1)
- Les **paramètres hors norme OMS affichés en rouge**
- Un **graphique SHAP** expliquant la décision pour cet échantillon spécifique
- Un **tableau récapitulatif** de tous les paramètres avec leur statut

5.2 Architecture de l'application

TABLE 5.1 – Fichiers du projet et leurs rôles

Fichier	Rôle
1_eda.py	Exploration, visualisation, imputation KNN
2_modeling.py	Entraînement des 4 modèles, diagnostic overfitting, sélection automatique
3_optimization.py	Calibration du seuil, SHAP, validation croisée
app.py	Interface Streamlit — compatible toutes versions SHAP
best_model.pkl	Modèle XGBoost sérialisé
scaler.pkl	StandardScaler sérialisé
optimal_threshold.npy	Seuil de décision optimisé
requirements.txt	Dépendances Python

5.3 Lancer l'application

Listing 5.1 – Commandes pour lancer l'application

```
1 # Installation des dependances
2 pip install -r requirements.txt
```

```
3
4 # Execution dans l'ordre
5 python 1_eda.py
6 python 2_modeling.py
7 python 3_optimization.py
8
9 # Lancement de l'application
10 streamlit run app.py
11 # -> Ouvre automatiquement http://localhost:8501
```

5.4 Accès à l'application

L'application est déployée et accessible publiquement via Streamlit Cloud :

<https://projet-potabilite-eau-667gnpnfdko4imxs5vgx8a.streamlit.app/>

Pour une utilisation locale, il est également possible de lancer l'application en suivant ces étapes :

Listing 5.2 – Lancement en local

```
1 pip install -r requirements.txt
2 python 1_eda.py
3 python 2_modeling.py
4 python 3_optimization.py
5 streamlit run app.py
```

5.5 Code source

Le code source complet est disponible sur GitHub :

<https://github.com/Solangeilinga/projet-potabilite-eau.git>

Chapitre 6

Conclusion et Perspectives

6.1 Bilan du projet

Ce projet a permis de construire un pipeline complet de machine learning pour la prédiction de la potabilité de l'eau, depuis l'exploration des données jusqu'au déploiement d'une application terrain. Les principaux résultats sont :

- **Modèle XGBoost** sélectionné : AUC-ROC ≈ 0.70 , F1-Score ≈ 0.60
- **Overfitting corrigé** via régularisation RF et XGBoost
- **Seuil optimisé** $\tau^* \approx 0.40$ pour minimiser les faux négatifs dangereux
- **Top 3 features** (SHAP) : Sulfate, pH, Chloramines
- **Application Streamlit** fonctionnelle, déployable sur Streamlit Cloud
- **Code versionné** sur GitHub

6.2 Limites

1. Les performances (AUC ≈ 0.70) restent modérées, plafond connu de ce dataset lié au chevauchement des distributions et aux nombreuses valeurs manquantes.
2. Le dataset Kaggle ne provient pas spécifiquement d'Afrique de l'Ouest, une validation sur des données locales serait nécessaire avant déploiement réel.

6.3 Perspectives

1. **Données locales** : collecter des mesures terrain en Afrique de l'Ouest pour affiner le modèle sur le contexte cible.
2. **Ensemble plus robuste** : VotingClassifier (RF + XGBoost + GradientBoosting) pour pousser l'AUC.

Références

1. Aditya Kadiwal. *Water Potability Dataset*. Kaggle, 2021. <https://www.kaggle.com/datasets/adityakadiwal/water-potability>
2. World Health Organization. *Guidelines for Drinking-water Quality*, 4th edition. WHO Press, 2011.
3. Streamlit Inc. *Streamlit Documentation*. <https://docs.streamlit.io>